

Cadeias de Markov

Estatística e Probabilidade para Ciência da Computação

Código: MAD243

Oferecido por:

Prof. Hugo Carvalho (hugo@dme.ufrj.br)

Departamento de Métodos Estatísticos - DME

Instituto de Matemática - IM/UFRJ

Cadeias de Markov – Motivação e história

O que são Cadeias de Markov?



Figura 1: Motivador para Cadeias de Markov: um jogo de tabuleiro

O que são Cadeias de Markov?




Figura 2: Movimenta-se no jogo através do resultado do lançamento independente de dois dados

O que são Cadeias de Markov?





Figura 3: Obs.: Existem outras maneiras de ir para a prisão no Monopoly que não estão presentes no Banco Imobiliário.

O que são Cadeias de Markov?




Figura 4: Função de probabilidade da variável aleatória representando a soma no lançamento de dois dados honestos.

O que são Cadeias de Markov?




Figura 5: Probabilidade da localização no tabuleiro após uma rodada, levando em consideração somente os dados.

O que são Cadeias de Markov?




Figura 6: Probabilidade da localização no tabuleiro após uma rodada, com as regras completas do jogo.

O que são Cadeias de Markov?




Figura 7: Probabilidade da localização no tabuleiro após duas rodadas.

O que são Cadeias de Markov?




Figura 8: Probabilidade da localização no tabuleiro após três rodadas.

O que são Cadeias de Markov?




Figura 9: Probabilidade da localização no tabuleiro após quatro rodadas.

O que são Cadeias de Markov?




Figura 10: Probabilidade da localização no tabuleiro após cinco rodadas.

O que são Cadeias de Markov?




Figura 11: Probabilidade da localização no tabuleiro após seis rodadas.

O que são Cadeias de Markov?




Figura 12: Probabilidade da localização no tabuleiro após sete rodadas.

O que são Cadeias de Markov?




Figura 13: Probabilidade da localização no tabuleiro após oito rodadas.

O que são Cadeias de Markov?




Figura 14: Probabilidade da localização no tabuleiro após nove rodadas.

O que são Cadeias de Markov?




Figura 15: Probabilidade da localização no tabuleiro após dez rodadas.

O que são Cadeias de Markov?




Figura 16: Probabilidade da localização no tabuleiro após infinitas rodadas.

Fonte: http://carlabernard.ch/beni/downloads/bernard_monopoly.pdf

Conceitos importantes

- Estados de uma cadeia
 \Rightarrow casas do tabuleiro

Conceitos importantes

- Estados de uma cadeia
 - ⇒ casas do tabuleiro
- Probabilidades de transição
 - ⇒ soma das faces para cima no lançamento de dois dados

Conceitos importantes

- Estados de uma cadeia
 - ⇒ casas do tabuleiro
- Probabilidades de transição
 - ⇒ soma das faces para cima no lançamento de dois dados
- Distribuição estacionária
 - ⇒ localização no tabuleiro após infinitas rodadas

Cadeias de Markov

Definição: Uma *cadeia de Markov* é uma sequência infinita de variáveis aleatórias $X_0, X_1, X_2, \dots, X_n, \dots$

Cadeias de Markov

Definição: Uma *cadeia de Markov* é uma sequência infinita de variáveis aleatórias $X_0, X_1, X_2, \dots, X_n, \dots$ tais que X_{n+1} é independente de $X_{n-1}, X_{n-2}, \dots, X_2, X_1, X_0$ caso se conheça X_n .

Cadeias de Markov

Definição: Uma *cadeia de Markov* é uma sequência infinita de variáveis aleatórias $X_0, X_1, X_2, \dots, X_n, \dots$ tais que X_{n+1} é independente de $X_{n-1}, X_{n-2}, \dots, X_2, X_1, X_0$ caso se conheça X_n .

Definição: Os possíveis valores assumidos pelas variáveis aleatórias são os *estados* da cadeia.

Cadeias de Markov

Definição: Uma *cadeia de Markov* é uma sequência infinita de variáveis aleatórias $X_0, X_1, X_2, \dots, X_n, \dots$ tais que X_{n+1} é independente de $X_{n-1}, X_{n-2}, \dots, X_2, X_1, X_0$ caso se conheça X_n .

Definição: Os possíveis valores assumidos pelas variáveis aleatórias são os *estados* da cadeia.

⇒ É possível fazer uma previsão acerca do futuro conhecendo-se somente o valor atual!

História

- Andrei Markov, 1906: “Extensão da lei dos grandes números para quantidades que dependem uma das outras”



A. A. Марков (1886).

História

- Trabalho não motivado por razões práticas, mas por uma disputa de ideias com Pavel Nekrasov



- Suas disputas iam além da Matemática: religião, filosofia, política, etc...

“História”

- Caixa com 3.000 pedras brancas e 2.000 pedras pretas
- Experimento: escolher pedra aleatoriamente, com reposição
- X_t = cor da pedra escolhida no sorteio t , para $t = 1, 2, 3, \dots$
- $\mathcal{C} = \{\text{preta, branca}\}$

“História”

- Caixa com 3.000 pedras brancas e 2.000 pedras pretas
- Experimento: escolher pedra aleatoriamente, com reposição
- $X_t =$ cor da pedra escolhida no sorteio t , para $t = 1, 2, 3, \dots$
- $\mathcal{C} = \{\text{preta, branca}\}$
- $(X_t)_{t \in \mathbb{N}}$ são variáveis aleatórias independentes:

$$\mathbb{P}(X_{t_1} = c_{t_1}, \dots, X_{t_k} = c_{t_k}) = \mathbb{P}(X_{t_1} = c_{t_1}) \dots \mathbb{P}(X_{t_k} = c_{t_k}),$$

para todos $k \geq 2$ e $c_{t_1}, \dots, c_{t_k} \in \mathcal{C}$, se $t_1 < t_2 < \dots < t_k$.

“História”

- Caixa com 3.000 pedras brancas e 2.000 pedras pretas
- Experimento: escolher pedra aleatoriamente, com reposição
- $X_t =$ cor da pedra escolhida no sorteio t , para $t = 1, 2, 3, \dots$
- $\mathcal{C} = \{\text{preta, branca}\}$
- $(X_t)_{t \in \mathbb{N}}$ são variáveis aleatórias independentes:

$$\mathbb{P}(X_{t_1} = c_{t_1}, \dots, X_{t_k} = c_{t_k}) = \mathbb{P}(X_{t_1} = c_{t_1}) \dots \mathbb{P}(X_{t_k} = c_{t_k}),$$

para todos $k \geq 2$ e $c_{t_1}, \dots, c_{t_k} \in \mathcal{C}$, se $t_1 < t_2 < \dots < t_k$.

- $\mathbb{P}(\text{pedra preta ser escolhida}) = 2/5$

“História”

E se não soubéssemos a proporção verdadeira
de pedras brancas e pretas na caixa?

“História”

E se não soubéssemos a proporção verdadeira
de pedras brancas e pretas na caixa?

- Fazer uma “longa” sequência de retiradas
- Calcular $\frac{\text{pedras pretas retiradas}}{\text{total de pedras retiradas}}$

“História”

**E se não soubéssemos a proporção verdadeira
de pedras brancas e pretas na caixa?**

- Fazer uma “longa” sequência de retiradas
- Calcular $\frac{\text{pedras pretas retiradas}}{\text{total de pedras retiradas}}$
- Jacob Bernoulli, 1713: “*Com um número suficientemente grande de observações, a proporção computada, com alta probabilidade, estará próxima do valor verdadeiro de 2/5*” – Lei Fraca dos Grandes Números

“História”

**E se não soubéssemos a proporção verdadeira
de pedras brancas e pretas na caixa?**

- Fazer uma “longa” sequência de retiradas
- Calcular $\frac{\text{pedras pretas retiradas}}{\text{total de pedras retiradas}}$
- Jacob Bernoulli, 1713: “*Com um número suficientemente grande de observações, a proporção computada, com alta probabilidade, estará próxima do valor verdadeiro de $2/5$* ” – Lei Fraca dos Grandes Números
- Lei Forte dos Grandes Números: “*a probabilidade de observar uma sequência de infinitas observações que leve a uma estimação incorreta do valor verdadeiro de $2/5$ é nula*”

“História”

**E se não soubéssemos a proporção verdadeira
de pedras brancas e pretas na caixa?**

- Fazer uma “longa” sequência de retiradas
- Calcular $\frac{\text{pedras pretas retiradas}}{\text{total de pedras retiradas}}$
- Jacob Bernoulli, 1713: “*Com um número suficientemente grande de observações, a proporção computada, com alta probabilidade, estará próxima do valor verdadeiro de $2/5$* ” – Lei Fraca dos Grandes Números
- Lei Forte dos Grandes Números: “*a probabilidade de observar uma sequência de infinitas observações que leve a uma estimação incorreta do valor verdadeiro de $2/5$ é nula*”

É assumida a independência entre as variáveis aleatórias!

“História”

Observações:



$k = 999$





Figura 17: Ilustração do processo de estimativa descrito acima.

Fonte: Lucas Simões Maia - *Formalismos da Composição Algorítmica: Um Experimento com Canções Folclóricas Brasileiras* (dissertação de Mestrado em Engenharia Elétrica)

“História”

- Agora, temos duas caixas:
 - Caixa I: 2.000 pedras brancas e 2.000 pedras pretas
 - Caixa II: 3.000 pedras brancas e 2.000 pedras pretas
- Experimento (sorteios com reposição):

“História”

- Agora, temos duas caixas:
 - Caixa I: 2.000 pedras brancas e 2.000 pedras pretas
 - Caixa II: 3.000 pedras brancas e 2.000 pedras pretas
- Experimento (sorteios com reposição):
 - 1) A primeira pedra c_1 é escolhida ao acaso da caixa II

“História”

- Agora, temos duas caixas:
 - Caixa I: 2.000 pedras brancas e 2.000 pedras pretas
 - Caixa II: 3.000 pedras brancas e 2.000 pedras pretas
- Experimento (sorteios com reposição):
 - 1) A primeira pedra c_1 é escolhida ao acaso da caixa II
 - 2) para $k \geq 2$:
 - i) Se a pedra anterior c_{k-1} é preta, a pedra c_k é escolhida ao acaso da caixa I
 - ii) Caso contrário, se a pedra anterior c_{k-1} é branca, a pedra c_k é escolhida da caixa II

“História”

- Agora, temos duas caixas:
 - Caixa I: 2.000 pedras brancas e 2.000 pedras pretas
 - Caixa II: 3.000 pedras brancas e 2.000 pedras pretas
- Experimento (sorteios com reposição):
 - 1) A primeira pedra c_1 é escolhida ao acaso da caixa II
 - 2) para $k \geq 2$:
 - i) Se a pedra anterior c_{k-1} é preta, a pedra c_k é escolhida ao acaso da caixa I
 - ii) Caso contrário, se a pedra anterior c_{k-1} é branca, a pedra c_k é escolhida da caixa II
- Agora $(X_t)_{t \in \mathbb{N}}$ não são independentes!

“História”

- Agora $\frac{\text{pedras retiradas da caixa I}}{\text{total de pedras retiradas}}$ converge para a probabilidade de se retirar uma pedra preta?

“História”

- Agora $\frac{\text{pedras retiradas da caixa I}}{\text{total de pedras retiradas}}$ converge para a probabilidade de se retirar uma pedra preta?
 - **Observação:** Note que só se retira uma pedra da caixa I se a pedra anteriormente sorteada é preta!

“História”

- Agora $\frac{\text{pedras retiradas da caixa I}}{\text{total de pedras retiradas}}$ converge para a probabilidade de se retirar uma pedra preta?
 - **Observação:** Note que só se retira uma pedra da caixa I se a pedra anteriormente sorteada é preta!
 - P. Nekrasov, 1902: “*Não! Independência é necessária para valer uma Lei dos Grandes Números*” – argumentos religiosos, baseados em livre arbítrio, não rigorosos

“História”

- Agora $\frac{\text{pedras retiradas da caixa I}}{\text{total de pedras retiradas}}$ converge para a probabilidade de se retirar uma pedra preta?
 - **Observação:** Note que só se retira uma pedra da caixa I se a pedra anteriormente sorteada é preta!
 - P. Nekrasov, 1902: “*Não! Independência é necessária para valer uma Lei dos Grandes Números*” – argumentos religiosos, baseados em livre arbítrio, não rigorosos
 - A. Markov, 1906: “*Talvez! Existem processos dependentes para os quais vale uma Lei dos Grandes Números*” – argumentos rigorosos

“História”

- Agora $\frac{\text{pedras retiradas da caixa I}}{\text{total de pedras retiradas}}$ converge para a probabilidade de se retirar uma pedra preta?
 - **Observação:** Note que só se retira uma pedra da caixa I se a pedra anteriormente sorteada é preta!
 - P. Nekrasov, 1902: “*Não! Independência é necessária para valer uma Lei dos Grandes Números*” – argumentos religiosos, baseados em livre arbítrio, não rigorosos
 - A. Markov, 1906: “*Talvez! Existem processos dependentes para os quais vale uma Lei dos Grandes Números*” – argumentos rigorosos
- Para mais detalhes, veja E. Seneta, 2013 – “A Tricentenary history of the Law of Large Numbers”

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663
- Redescoberto em 1917, A. Erlang – Teoria de Filas

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663
- Redescoberto em 1917, A. Erlang – Teoria de Filas
- C. Shannon, 1948 – Teoria da Informação

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663
- Redescoberto em 1917, A. Erlang – Teoria de Filas
- C. Shannon, 1948 – Teoria da Informação
- Algoritmo PageRank (Google)

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663
- Redescoberto em 1917, A. Erlang – Teoria de Filas
- C. Shannon, 1948 – Teoria da Informação
- Algoritmo PageRank (Google)
- Modelar linguagens

Aplicações

- Primeiro uso “prático” de cadeias de Markov (Markov, 1913):
 - Análise do poema *Eugene Onegin*, de Aleksandr Pushkin
 - Sequência de 20.000 caracteres (!)
 - Probabilidade (estacionária) de vogais: 0,432
 - Probabilidade de uma vogal ser seguida de uma vogal: 0,128
 - Probabilidade de uma consoante ser seguida de uma vogal: 0,663
- Redescoberto em 1917, A. Erlang – Teoria de Filas
- C. Shannon, 1948 – Teoria da Informação
- Algoritmo PageRank (Google)
- Modelar linguagens

Mais aplicações na Wikipedia!

Cadeias de Markov

Definição

Definição: Uma sequência $(X_t)_{t \in \mathbb{N}}$ de variáveis aleatórias é dita uma *cadeia de Markov* se assumem valores no mesmo conjunto finito \mathcal{C} e satisfazem

$$\begin{aligned}\mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_2 = x_2, X_1 = x_1) \\ = \mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n),\end{aligned}$$

para todos $n \in \mathbb{N}$ e $x_{n+1}, \dots, x_1 \in \mathcal{C}$.

Definição

Definição: Uma sequência $(X_t)_{t \in \mathbb{N}}$ de variáveis aleatórias é dita uma *cadeia de Markov* se assumem valores no mesmo conjunto finito \mathcal{C} e satisfazem

$$\begin{aligned}\mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_2 = x_2, X_1 = x_1) \\ = \mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n),\end{aligned}$$

para todos $n \in \mathbb{N}$ e $x_{n+1}, \dots, x_1 \in \mathcal{C}$.

- Elementos de \mathcal{C} : *estados* da cadeia

Definição

Definição: Uma sequência $(X_t)_{t \in \mathbb{N}}$ de variáveis aleatórias é dita uma *cadeia de Markov* se assumem valores no mesmo conjunto finito \mathcal{C} e satisfazem

$$\begin{aligned}\mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_2 = x_2, X_1 = x_1) \\ = \mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n),\end{aligned}$$

para todos $n \in \mathbb{N}$ e $x_{n+1}, \dots, x_1 \in \mathcal{C}$.

- Elementos de \mathcal{C} : *estados* da cadeia
- $p_{ij}(n) := \mathbb{P}(X_{n+1} = x_j | X_n = x_i)$: *probabilidades de transição*
 - “*probabilidade de ir para o estado x_j no tempo $n + 1$, dado que no tempo n a posição é x_i* ”

Definição

Definição: Uma sequência $(X_t)_{t \in \mathbb{N}}$ de variáveis aleatórias é dita uma *cadeia de Markov* se assumem valores no mesmo conjunto finito \mathcal{C} e satisfazem


$$\begin{aligned}\mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_2 = x_2, X_1 = x_1) \\ = \mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n),\end{aligned}$$

para todos $n \in \mathbb{N}$ e $x_{n+1}, \dots, x_1 \in \mathcal{C}$.

- Elementos de \mathcal{C} : *estados* da cadeia
- $p_{ij}(n) := \mathbb{P}(X_{n+1} = x_j | X_n = x_i)$: *probabilidades de transição*
 - “*probabilidade de ir para o estado x_j no tempo $n + 1$, dado que no tempo n a posição é x_i* ”
- $p_{ij}(n)$ não depende de $n \implies$ *cadeia homogênea*:

$$p_{ij} = \mathbb{P}(X_{n+1} = x_j | X_n = x_i), \quad \forall n$$

Diagrama e matriz de transição




$$X_k \begin{bmatrix} q_1 \\ q_2 \\ q_3 \end{bmatrix} \quad X_{k+1} \begin{bmatrix} p_{11} & p_{12} & p_{13} \\ p_{21} & p_{22} & p_{23} \\ p_{31} & p_{32} & p_{33} \end{bmatrix}$$

Fonte: Lucas Simões Maia - *Formalismos da Composição Algorítmica: Um Experimento com Canções Folclóricas Brasileiras* (dissertação de Mestrado em Engenharia Elétrica)

Um exemplo

Diagrama e probabilidades de transição (genérica):



Um exemplo

Matriz de transição (genérica e específica):

$$\mathbf{P} = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \\ p_{41} & p_{42} & p_{43} & p_{44} \end{bmatrix} = \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix}$$

$p_{ij} = \mathbb{P}(X_{n+1} = x_j | X_n = x_i), \forall n \implies$ cadeia homogênea

Um exemplo

Matriz de transição (genérica e específica):

$$\mathbf{P} = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \\ p_{41} & p_{42} & p_{43} & p_{44} \end{bmatrix} = \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix}$$

Um exemplo


Matriz de transição (genérica e específica):

$$\mathbf{P} = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \\ p_{41} & p_{42} & p_{43} & p_{44} \end{bmatrix} = \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix}$$

$p_{ij} = \mathbb{P}(X_{n+1} = x_j | X_n = x_i), \forall n \implies$ cadeia homogênea

Um exemplo

Diagrama e probabilidades de transição (específica):



Um exemplo

Algumas perguntas:

- 1) Dado que o estado inicial é c_1 , qual é a distribuição de probabilidade do segundo estado?
- 2) E do terceiro estado?
- 3) Em média, após um longo tempo, qual proporção de tempo a cadeia passa em cada estado?

Um exemplo

1) Dado que o estado inicial é $c_1\dots$

$$\pi_0 = [1 \ 0 \ 0 \ 0] \implies \text{distribuição inicial}$$

Um exemplo

1) Dado que o estado inicial é $c_1\dots$

$$\pi_0 = [1 \ 0 \ 0 \ 0] \implies \text{distribuição inicial}$$

qual é a distribuição de probabilidade do segundo estado?

Um exemplo

1) Dado que o estado inicial é $c_1\dots$

$$\pi_0 = [1 \ 0 \ 0 \ 0] \implies \text{distribuição inicial}$$

qual é a distribuição de probabilidade do segundo estado?

$$\pi_1 = \pi_0 \mathbf{P}$$

$$= [1 \ 0 \ 0 \ 0] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix}$$
$$= [0 \ 0.5 \ 0.3 \ 0.2]$$

Um exemplo

1) Dado que o estado inicial é $c_1\dots$

$$\pi_0 = [1 \ 0 \ 0 \ 0] \implies \text{distribuição inicial}$$

qual é a distribuição de probabilidade do segundo estado?

$$\pi_1 = \pi_0 \mathbf{P}$$

$$= [1 \ 0 \ 0 \ 0] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix}$$
$$= [0 \ 0.5 \ 0.3 \ 0.2]$$

Um exemplo

2) Qual a distribuição de probabilidade do terceiro estado?

Um exemplo

2) Qual a distribuição de probabilidade do terceiro estado?

$$\begin{aligned}\pi_2 &= \pi_1 \mathbf{P} \\ &= \pi_0 \mathbf{P} \mathbf{P} \\ &= (\pi_0 \mathbf{P}) \mathbf{P} \text{ ou } \pi_0 (\mathbf{P} \mathbf{P})\end{aligned}$$

Um exemplo

2) Qual a distribuição de probabilidade do terceiro estado?

$$\begin{aligned}\pi_2 &= \pi_1 \mathbf{P} \\ &= \pi_0 \mathbf{P} \mathbf{P} \\ &= (\pi_0 \mathbf{P}) \mathbf{P} \text{ ou } \pi_0 (\mathbf{P} \mathbf{P})\end{aligned}$$

$$\begin{aligned}(\pi_0 \mathbf{P}) \mathbf{P} &= \pi_1 \mathbf{P} \\ &= [0 \ 0.5 \ 0.3 \ 0.2] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix} \\ &= [0.21 \ 0.20 \ 0.23 \ 0.36]\end{aligned}$$

Um exemplo

2) Qual a distribuição de probabilidade do terceiro estado?

$$\begin{aligned}\pi_2 &= \pi_1 \mathbf{P} \\ &= \pi_0 \mathbf{P} \mathbf{P} \\ &= (\pi_0 \mathbf{P}) \mathbf{P} \text{ ou } \pi_0 (\mathbf{P} \mathbf{P})\end{aligned}$$

$$\begin{aligned}(\pi_0 \mathbf{P}) \mathbf{P} &= \pi_1 \mathbf{P} \\ &= [0 \ 0.5 \ 0.3 \ 0.2] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix} \\ &= [0.21 \ 0.20 \ 0.23 \ 0.36]\end{aligned}$$

Um exemplo

$$\begin{aligned}\pi_0(\mathbf{P}\mathbf{P}) &= [1 \ 0 \ 0 \ 0] \begin{pmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{pmatrix} \\ &= [1 \ 0 \ 0 \ 0] \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} \\ &= [0.21 \ 0.20 \ 0.23 \ 0.36]\end{aligned}$$

Um exemplo

$$\pi_0(\mathbf{P}\mathbf{P}) = [1 \ 0 \ 0 \ 0] \begin{pmatrix} [0 \ 0.5 \ 0.3 \ 0.2] & [0 \ 0.5 \ 0.3 \ 0.2] \\ [0.1 \ 0 \ 0.3 \ 0.6] & [0.1 \ 0 \ 0.3 \ 0.6] \\ [0.2 \ 0.6 \ 0 \ 0.2] & [0.2 \ 0.6 \ 0 \ 0.2] \\ [0.5 \ 0.1 \ 0.4 \ 0] & [0.5 \ 0.1 \ 0.4 \ 0] \end{pmatrix}$$
$$= [0.21 \ 0.20 \ 0.23 \ 0.36]$$

Um exemplo

$$\begin{aligned}\pi_0(\mathbf{P}\mathbf{P}) &= [1 \ 0 \ 0 \ 0] \begin{pmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{pmatrix} \\ &= [1 \ 0 \ 0 \ 0] \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} \\ &= [0.21 \ 0.20 \ 0.23 \ 0.36]\end{aligned}$$

Um exemplo

$$\mathbf{P}^2 = \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} = \begin{bmatrix} p_{11}^{(2)} & p_{12}^{(2)} & p_{13}^{(2)} & p_{14}^{(2)} \\ p_{21}^{(2)} & p_{22}^{(2)} & p_{23}^{(2)} & p_{24}^{(2)} \\ p_{31}^{(2)} & p_{32}^{(2)} & p_{33}^{(2)} & p_{34}^{(2)} \\ p_{41}^{(2)} & p_{42}^{(2)} & p_{43}^{(2)} & p_{44}^{(2)} \end{bmatrix}$$

Um exemplo

$$\mathbf{P}^2 = \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} = \begin{bmatrix} p_{11}^{(2)} & p_{12}^{(2)} & p_{13}^{(2)} & p_{14}^{(2)} \\ p_{21}^{(2)} & p_{22}^{(2)} & p_{23}^{(2)} & p_{24}^{(2)} \\ p_{31}^{(2)} & p_{32}^{(2)} & p_{33}^{(2)} & p_{34}^{(2)} \\ p_{41}^{(2)} & p_{42}^{(2)} & p_{43}^{(2)} & p_{44}^{(2)} \end{bmatrix}$$

$$p_{ij}^{(2)} = \mathbb{P}(X_{n+2} = x_j | X_n = x_i), \quad (\forall n)$$

$$= \sum_k \mathbb{P}(X_{n+2} = x_j | X_{n+1} = x_k) \mathbb{P}(X_{n+1} = x_k | X_n = x_i)$$

Um exemplo

$$\mathbf{P}^2 = \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} = \begin{bmatrix} p_{11}^{(2)} & p_{12}^{(2)} & p_{13}^{(2)} & p_{14}^{(2)} \\ p_{21}^{(2)} & p_{22}^{(2)} & p_{23}^{(2)} & p_{24}^{(2)} \\ p_{31}^{(2)} & p_{32}^{(2)} & p_{33}^{(2)} & p_{34}^{(2)} \\ p_{41}^{(2)} & p_{42}^{(2)} & p_{43}^{(2)} & p_{44}^{(2)} \end{bmatrix}$$

$$\begin{aligned} p_{ij}^{(2)} &= \mathbb{P}(X_{n+2} = x_j | X_n = x_i), \quad (\forall n) \\ &= \sum_k \mathbb{P}(X_{n+2} = x_j | X_{n+1} = x_k) \mathbb{P}(X_{n+1} = x_k | X_n = x_i) \end{aligned}$$

Mais geralmente...

$$\mathbf{P}^m \text{ tem elementos } p_{ij}^{(\textcolor{red}{m})} = \mathbb{P}(X_{n+\textcolor{red}{m}} = x_j | X_n = x_i), \quad \forall n$$

Um exemplo

$$\mathbf{P}^2 = \begin{bmatrix} 0.21 & 0.20 & 0.23 & 0.36 \\ 0.36 & 0.29 & 0.27 & 0.08 \\ 0.16 & 0.12 & 0.32 & 0.40 \\ 0.09 & 0.49 & 0.18 & 0.24 \end{bmatrix} = \begin{bmatrix} p_{11}^{(2)} & p_{12}^{(2)} & p_{13}^{(2)} & p_{14}^{(2)} \\ p_{21}^{(2)} & p_{22}^{(2)} & p_{23}^{(2)} & p_{24}^{(2)} \\ p_{31}^{(2)} & p_{32}^{(2)} & p_{33}^{(2)} & p_{34}^{(2)} \\ p_{41}^{(2)} & p_{42}^{(2)} & p_{43}^{(2)} & p_{44}^{(2)} \end{bmatrix}$$

$$\begin{aligned} p_{ij}^{(2)} &= \mathbb{P}(X_{n+2} = x_j | X_n = x_i), \quad (\forall n) \\ &= \sum_k \mathbb{P}(X_{n+2} = x_j | X_{n+1} = x_k) \mathbb{P}(X_{n+1} = x_k | X_n = x_i) \end{aligned}$$

Mais geralmente...

$$\begin{aligned} \mathbf{P}^m \text{ tem elementos } p_{ij}^{(\textcolor{red}{m})} &= \mathbb{P}(X_{n+\textcolor{red}{m}} = x_j | X_n = x_i), \quad \forall n \\ \implies \text{Equações de Chapman-Kolmogorov} \end{aligned}$$

Um exemplo

3) Em média, após um longo tempo, qual proporção de tempo a cadeia passa em cada estado?

Um exemplo

3) Em média, após um longo tempo, qual proporção de tempo a cadeia passa em cada estado?

$$\begin{aligned} p_{ij}^{(\textcolor{red}{m})} &= \mathbb{P}(X_{n+\textcolor{red}{m}} = x_j | X_n = x_i) \\ &= \mathbb{P}(X_{\textcolor{red}{m}} = x_j | X_0 = x_i) \end{aligned}$$

Um exemplo

3) Em média, após um longo tempo, qual proporção de tempo a cadeia passa em cada estado?

$$\begin{aligned} p_{ij}^{(\textcolor{red}{m})} &= \mathbb{P}(X_{n+\textcolor{red}{m}} = x_j | X_n = x_i) \\ &= \mathbb{P}(X_{\textcolor{red}{m}} = x_j | X_0 = x_i) \end{aligned}$$

$$\implies p_{ij}^{(\infty)} = \mathbb{P}(X_{\infty} = x_j | X_0 = x_i)$$

Um exemplo

3) Em média, após um longo tempo, qual proporção de tempo a cadeia passa em cada estado?

$$\begin{aligned} p_{ij}^{(\textcolor{red}{m})} &= \mathbb{P}(X_{n+\textcolor{red}{m}} = x_j | X_n = x_i) \\ &= \mathbb{P}(X_{\textcolor{red}{m}} = x_j | X_0 = x_i) \end{aligned}$$

$$\implies p_{ij}^{(\infty)} = \mathbb{P}(X_{\infty} = x_j | X_0 = x_i)$$

$$P^{\infty} \approx \begin{bmatrix} 0.2083 & 0.2807 & 0.2508 & 0.2602 \\ 0.2083 & 0.2807 & 0.2508 & 0.2602 \\ 0.2083 & 0.2807 & 0.2508 & 0.2602 \\ 0.2083 & 0.2807 & 0.2508 & 0.2602 \end{bmatrix}$$

Um exemplo

$$\pi_{\infty} = [0.2083 \ 0.2807 \ 0.2508 \ 0.2602]$$

\implies Distribuição estacionária

Um exemplo

$$\boldsymbol{\pi}_\infty = [0.2083 \ 0.2807 \ 0.2508 \ 0.2602]$$

\implies Distribuição estacionária

$$\begin{aligned}\boldsymbol{\pi}_\infty \mathbf{P} &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix} \\ &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \\ &= \boldsymbol{\pi}_\infty\end{aligned}$$

\implies A distribuição estacionária satisfaz $\boldsymbol{\pi} \mathbf{P} = \boldsymbol{\pi}!$

Um exemplo

$$\pi_\infty = [0.2083 \ 0.2807 \ 0.2508 \ 0.2602]$$

\implies Distribuição estacionária

$$\begin{aligned}\pi_\infty \mathbf{P} &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix} \\ &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \\ &= \pi_\infty\end{aligned}$$

Um exemplo

$$\boldsymbol{\pi}_\infty = [0.2083 \ 0.2807 \ 0.2508 \ 0.2602]$$

\implies Distribuição estacionária

$$\begin{aligned}\boldsymbol{\pi}_\infty \mathbf{P} &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \begin{bmatrix} 0 & 0.5 & 0.3 & 0.2 \\ 0.1 & 0 & 0.3 & 0.6 \\ 0.2 & 0.6 & 0 & 0.2 \\ 0.5 & 0.1 & 0.4 & 0 \end{bmatrix} \\ &= [0.2083 \ 0.2807 \ 0.2508 \ 0.2602] \\ &= \boldsymbol{\pi}_\infty\end{aligned}$$

\implies A distribuição estacionária satisfaz $\boldsymbol{\pi} \mathbf{P} = \boldsymbol{\pi}!$

Distribuição estacionária

Teorema (“Perron-Frobenius” e “Markov”): Seja \mathbf{P} a matriz de transição de uma cadeia de Markov $(X_n)_{n \in \mathbb{N}}$. Assuma que \mathbf{P} é *regular*, ou seja, \mathbf{P}^m tem todas as entradas positivas para algum valor de $m \geq 1$. Então vale que:

- i) A cadeia tem uma única distribuição estacionária $\boldsymbol{\pi}$;
- ii) Quando $m \rightarrow \infty$, \mathbf{P}^m converge para uma matriz cujas linhas são todas iguais a $\boldsymbol{\pi}$;
- iii) Vale o seguinte teorema limite: $\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N X_n \xrightarrow{p} \mathbb{E}[\boldsymbol{\pi}]$.

Obs.: Ao dispensar a independência, mais hipóteses são necessárias para garantir uma LGN!

Distribuições estacionária vs. limite

Teorema: Se π satisfaz a *equação de balanço detalhado*

$$\pi_i p_{ij} = p_{ji} \pi_j,$$

então π é uma distribuição estacionária para \mathbf{P} .

Distribuições estacionária vs. limite

Teorema: Se π satisfaz a *equação de balanço detalhado*

$$\pi_i p_{ij} = p_{ji} \pi_j,$$

então π é uma distribuição estacionária para \mathbf{P} .

- Distribuição **estacionária** – inalterada por \mathbf{P}

Distribuições estacionária vs. limite

Teorema: Se π satisfaz a *equação de balanço detalhado*

$$\pi_i p_{ij} = p_{ji} \pi_j,$$

então π é uma distribuição estacionária para \mathbf{P} .

- Distribuição **estacionária** – inalterada por \mathbf{P}
- Distribuição **limite** – $\pi_j =$ proporção de tempo gasta no estado x_j

Distribuições estacionária vs. limite

Teorema: Se π satisfaz a *equação de balanço detalhado*

$$\pi_i p_{ij} = p_{ji} \pi_j,$$

então π é uma distribuição estacionária para \mathbf{P} .

- Distribuição **estacionária** – inalterada por \mathbf{P}
- Distribuição **limite** – π_j = proporção de tempo gasta no estado x_j

Exemplo: $\mathbf{P} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ tem $\pi = [0.5 \ 0.5]$ como distribuição **estacionária**, mas não tem distribuição **limite**!

Distribuições estacionária vs. limite

Teorema: Se π satisfaz a *equação de balanço detalhado*

$$\pi_i p_{ij} = p_{ji} \pi_j,$$

então π é uma distribuição estacionária para \mathbf{P} .

- Distribuição **estacionária** – inalterada por \mathbf{P}
- Distribuição **limite** – π_j = proporção de tempo gasta no estado x_j

Exemplo: $\mathbf{P} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ tem $\pi = [0.5 \ 0.5]$ como distribuição **estacionária**, mas não tem distribuição **limite**!

Atenção: Estamos assumindo a matriz \mathbf{P} **conhecida**!

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)
- $\mathcal{J} = \{z_1, z_2, z_3, \dots, z_n\}$ observações – realização da cadeia

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)
- $\mathcal{J} = \{z_1, z_2, z_3, \dots, z_n\}$ observações – realização da cadeia
- $\widehat{\mathbf{M}}$ **matriz de contagem**: m_{ij} é a quantidade de vezes que a transição $x_i \rightarrow x_j$ acontece em \mathcal{J}

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)
- $\mathcal{J} = \{z_1, z_2, z_3, \dots, z_n\}$ observações – realização da cadeia
- $\widehat{\mathbf{M}}$ **matriz de contagem**: m_{ij} é a quantidade de vezes que a transição $x_i \rightarrow x_j$ acontece em \mathcal{J}
- $\widehat{\mathbf{P}}$ **matriz de transição estimada**: $\widehat{p}_{ij} = \frac{m_{ij}}{\sum_j m_{ij}}$, proporção das transições $x_i \rightarrow x_j$ dentre todas as transições partindo de x_i

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)
- $\mathcal{J} = \{z_1, z_2, z_3, \dots, z_n\}$ observações – realização da cadeia
- $\widehat{\mathbf{M}}$ **matriz de contagem**: m_{ij} é a quantidade de vezes que a transição $x_i \rightarrow x_j$ acontece em \mathcal{J}
- $\widehat{\mathbf{P}}$ **matriz de transição estimada**: $\widehat{p}_{ij} = \frac{m_{ij}}{\sum_j m_{ij}}$, proporção das transições $x_i \rightarrow x_j$ dentre todas as transições partindo de x_i
- **Estimativa de máxima verossimilhança**: “ $\widehat{\mathbf{P}}$ é a matriz de transição para a qual as observações \mathcal{J} são as mais prováveis”

Estimando uma matriz de transição

- X_1, X_2, X_3, \dots cadeia de Markov (homogênea)
- $\mathcal{J} = \{z_1, z_2, z_3, \dots, z_n\}$ observações – realização da cadeia
- $\widehat{\mathbf{M}}$ **matriz de contagem**: m_{ij} é a quantidade de vezes que a transição $x_i \rightarrow x_j$ acontece em \mathcal{J}
- $\widehat{\mathbf{P}}$ **matriz de transição estimada**: $\widehat{p}_{ij} = \frac{m_{ij}}{\sum_j m_{ij}}$, proporção das transições $x_i \rightarrow x_j$ dentre todas as transições partindo de x_i
- **Estimativa de máxima verossimilhança**: “ $\widehat{\mathbf{P}}$ é a matriz de transição para a qual as observações \mathcal{J} são as mais prováveis”
- **Estimador consistente**: “se $n \rightarrow \infty$, $\widehat{\mathbf{P}}$ converge para a matriz ‘verdadeira’ \mathbf{P} ”